

RELATÓRIO CONSUMO DE ENERGIA ELÉTRICA NO BRASIL (1963 a 2018)

Évelyn Muniz

SUMÁRIO

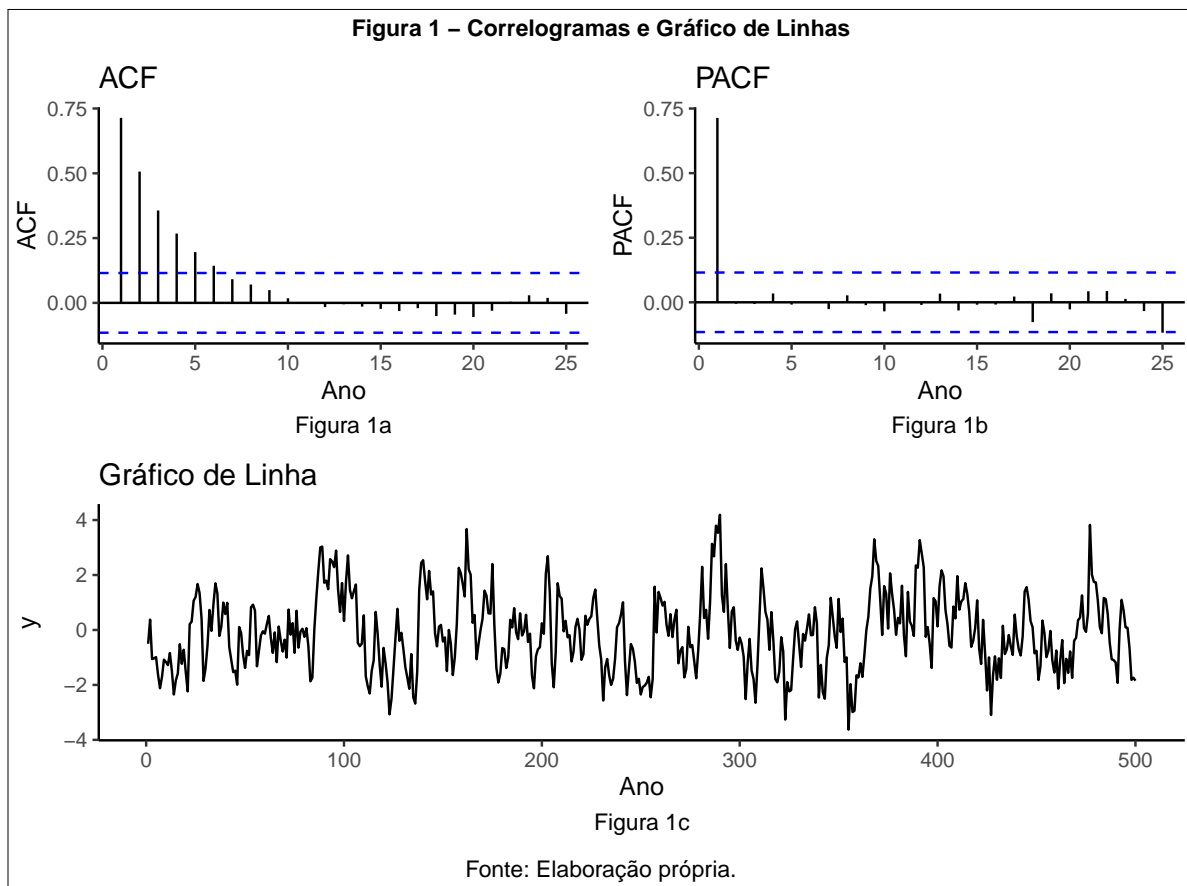
1	Dados Simulados:	1
1.1	Correlogramas:	1
1.2	Modelo:	2
1.2.1	Resíduos:	3
2	Estudo de Caso: Consumo de Energia Elétrica (1963 a 2018).	7
2.1	Introdução	7
2.2	METODOLOGIA E RESULTADOS	7
2.2.1	Modelo:	9
2.2.2	Modelo 2:	13
2.2.3	Comparação entre os modelos criados pela função arima e autoarima. . .	18

1 Dados Simulados:

Para fins didáticos de compreensão dos gráficos ACF e PACF:

1.1 Correlogramas:

Foi possível identificar autocorrelação até lag 6 no ACF com decaimento exponencial, indicando modelo ARIMA (1,d,0) e autocorrelação a partir do lag 25 no PACF, como pode ser visto na FIGURA 1 abaixo:



1.2 Modelo:

O modelo arima (1,0,0) com AR1 significativo e coeficientes dentro do intervalo $[-1, 1]$.

Series: y
ARIMA(1,0,0) with zero mean

Coefficients:
ar1
0.7168
s.e. 0.0311

sigma² = 0.9142: log likelihood = -686.9
AIC=1377.79 AICc=1377.81 BIC=1386.22

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	-0.03477895	0.9551671	0.7614712	-1420.406	2157.076	0.9196344

ACF1

Training set 0.002605597

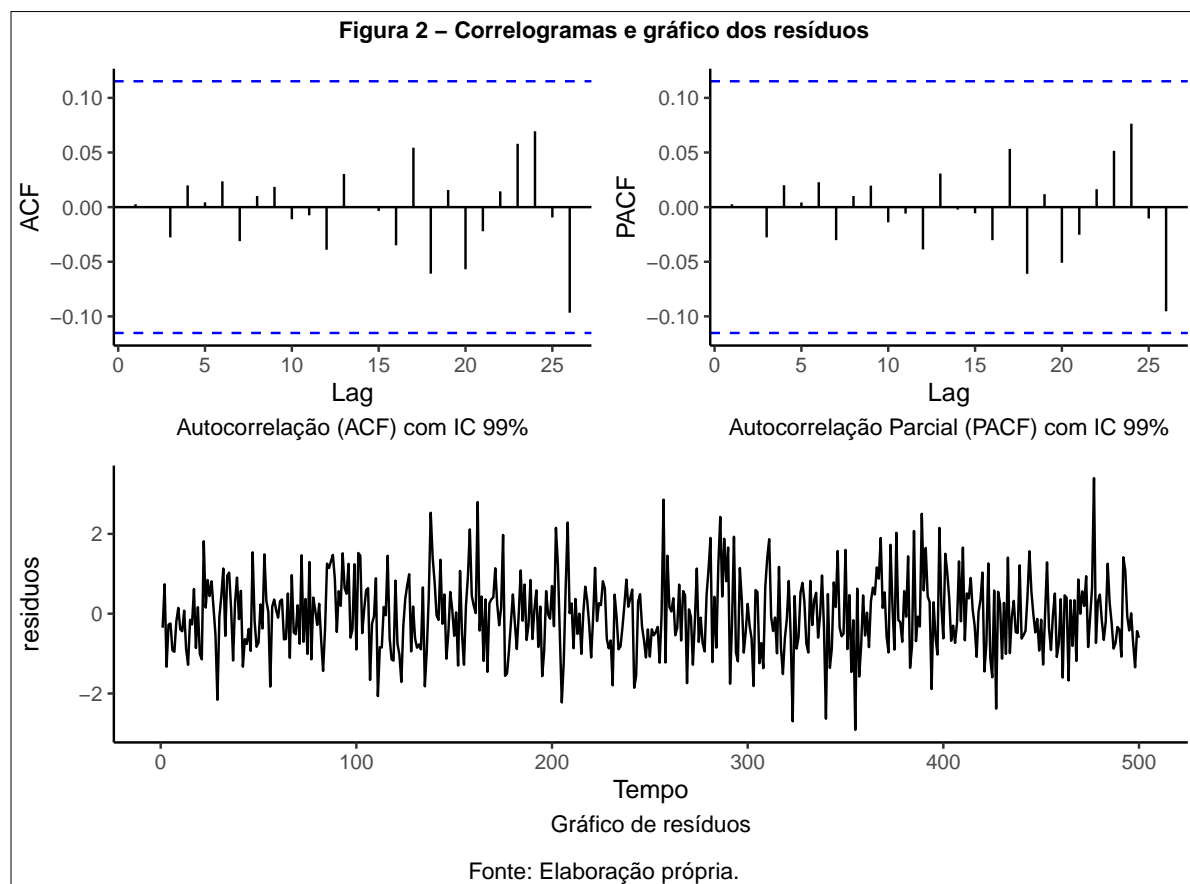
z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)
ar1	0.716813	0.031123	23.032	< 2.2e-16 ***


Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

1.2.1 Resíduos:

De acordo com a FIGURA 2 abaixo, é possível identificar que os resíduos não apresentaram autocorrelação a um nível de confiança de 99%.



A adequação do modelo com a série pode ser vista na FIGURA 3 abaixo:



1.2.1.1 Normalidade:

Abaixo, a FIGURA 4 mostra a análise de normalidade dos resíduos, por meio do histograma e q-qplot.

Figura 4 – Análise dos Resíduos Padronizados




Figura 4a: Histograma com curva de densidade




Figura 4b: QQ-plot dos resíduos padronizados

Fonte: Elaboração própria.

Graficamente os resíduos apresentam normalidade, mas para conferir maior robustez, foi realizado o teste de hipóteses de Shapiro-Wilk e o ad.test, sob as hipóteses:

H_0 : Os resíduos são normais H_1 : Os resíduos não apresentam normalidade.

Shapiro-Wilk normality test

data: sresiduos

W = 0.99416, p-value = 0.05225

Anderson-Darling normality test

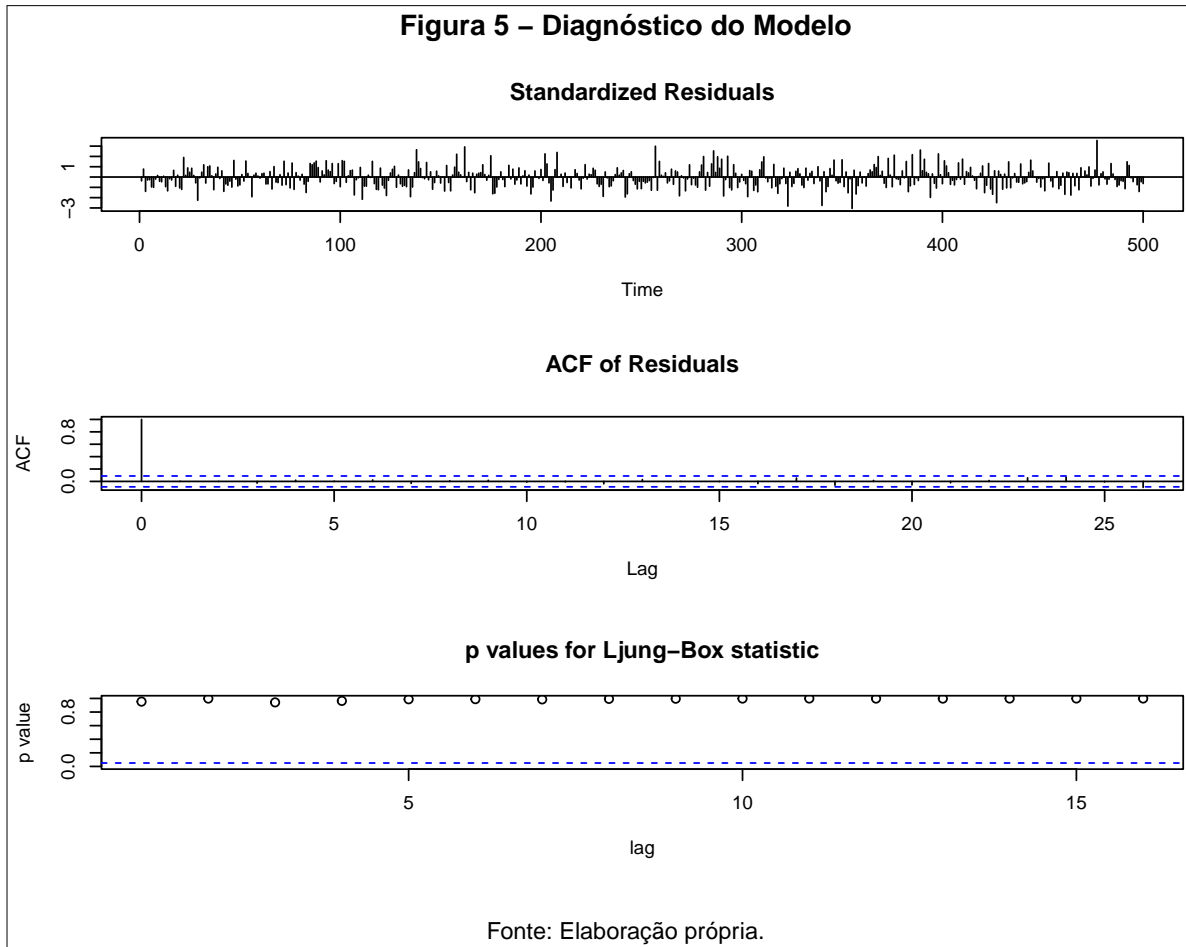
data: sresiduos

A = 0.83312, p-value = 0.03153

Com 99% de confiança, não há evidências para rejeição da hipótese nula, portanto, pode-se considerar que os resíduos seguem distribuição normal.

1.2.1.2 Autocorrelação:

A FIGURA 5 abaixo mostra o teste de Ljung-Box e o gráfico ACF para presença de autocorrelação nos resíduos:



O gráfico ACF e o de Ljung-Box não indicaram presença de autocorrelação nos resíduos. O teste de Ljung-Box sob as hipóteses:

H_0 : Não há autocorrelação dos resíduos H_1 : Os resíduos estão correlacionados.

Box-Ljung test

```
data:  residuos
X-squared = 0.60028, df = 5, p-value = 0.988
```

Com $p\text{-value} = 0,988$ não há evidências para rejeição da hipótese nula. Portanto é um resíduo branco gaussiano, uma vez que apresenta distribuição normal e independência.

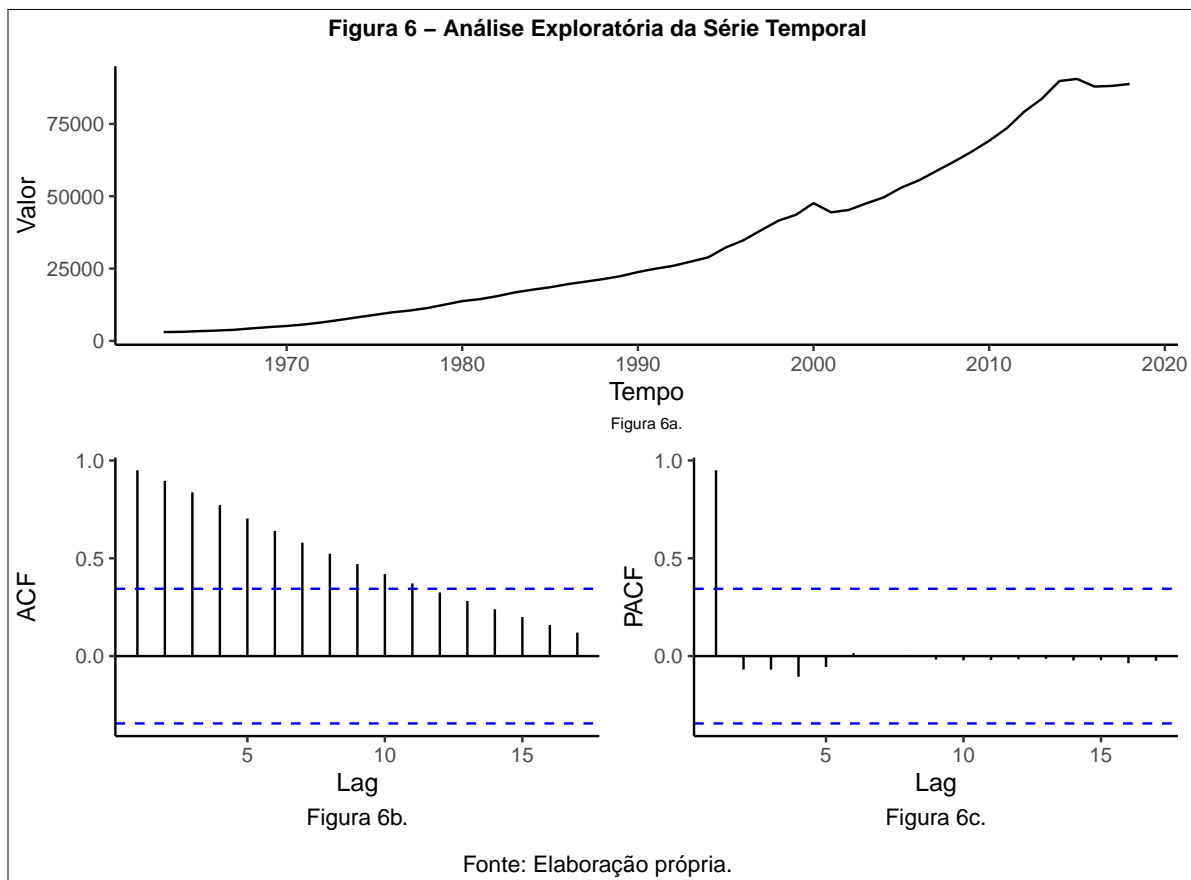
2 Estudo de Caso: Consumo de Energia Elétrica (1963 a 2018).

2.1 Introdução

Para este trabalho, foi utilizado o banco de dados do Consumo de Energia Elétrica no Brasil durante os anos de 1963 a 2018. Os dados tem frequência de uma observação por ano associadas ao consumo total daquele ano.

2.2 METODOLOGIA E RESULTADOS

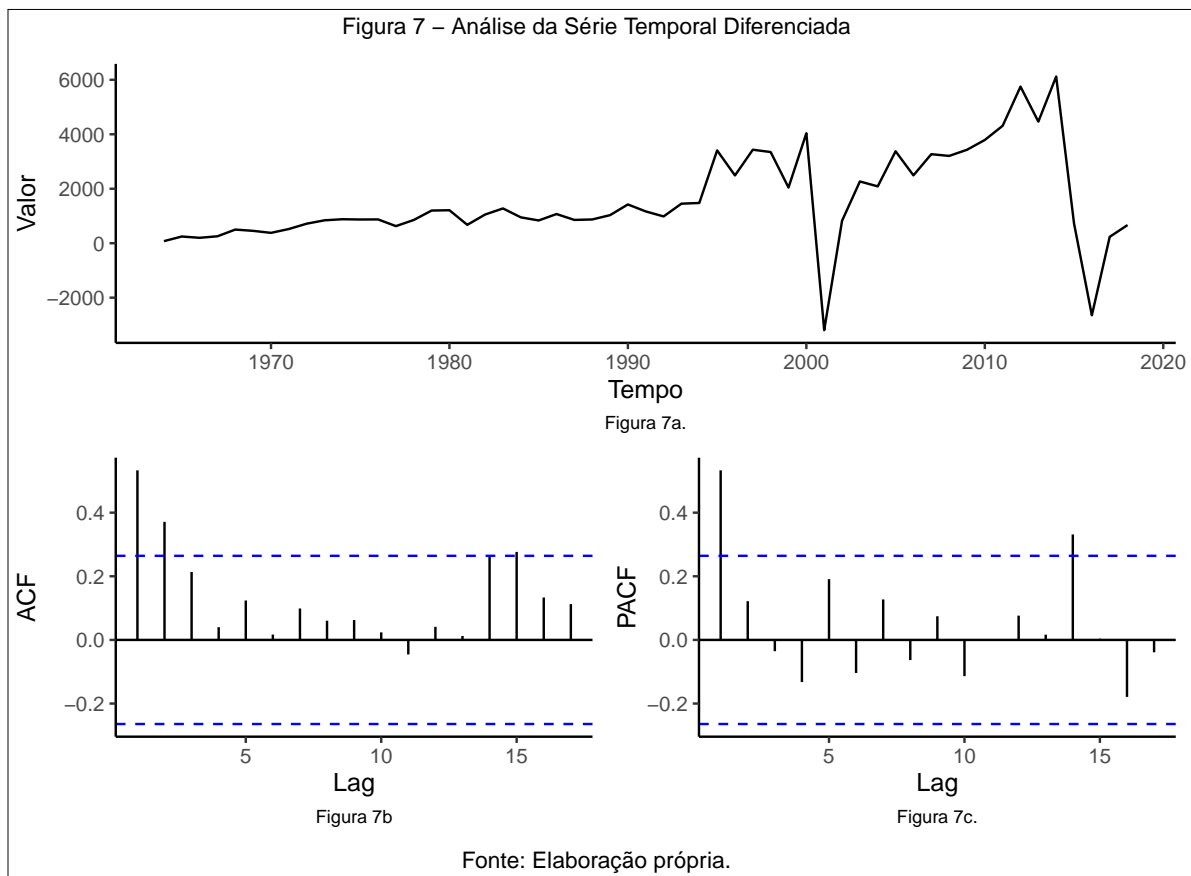
Após transformar os dados em um arquivo do tipo ts, foi feito o gráfico de linhas, o gráfico ACF e o PACF, como pode ser visto na FIGURA 6 abaixo, em que é possível notar um aparente crescimento ao longo dos anos, autocorrelação até o lag 12 com decaimento exponencial e ausência de autocorrelação parcial, com primeiro lag significativo.



A primeira diferenciação para tornar a série estacionária, aqui os parâmetros são estabelecidos com lag = número de posições que os elementos são subtraídos, dif = quantidade de vezes que a série será diferenciada

```
dif_y=diff(y,lag=1,dif=1)
```

A FIGURA 7 abaixo mostra a nova série após a diferenciação. O gráfico de linha que antes aparentava um crescimento quase que exponencial, agora indica crescimento mas também ciclos (FIGURA7a). É possível identificar autocorrelação só até o lag 2 (FIGURA7b) e autocorrelação a partir do lag 13 com decaimento alternado (FIGURA7c).



2.2.1 Modelo:

A partir da série diferenciada, surge o primeiro modelo, que teve como base:

- Sem constante autoregressora AR,
- 1 diferenciação (vista por `dif_y`) e
- 1 componente MA.

Abaixo, o ajuste do modelo Arima (0,1,1), que resultou na componente MA(1) significativa.

```
modelo <- Arima(y,order=c(0,1,1),include.constant=F)
coeftest(modelo)
```

z test of coefficients:

```


      Estimate Std. Error z value Pr(>|z|)
ma1  0.61261    0.10842  5.6501 1.603e-08 ***
---

```

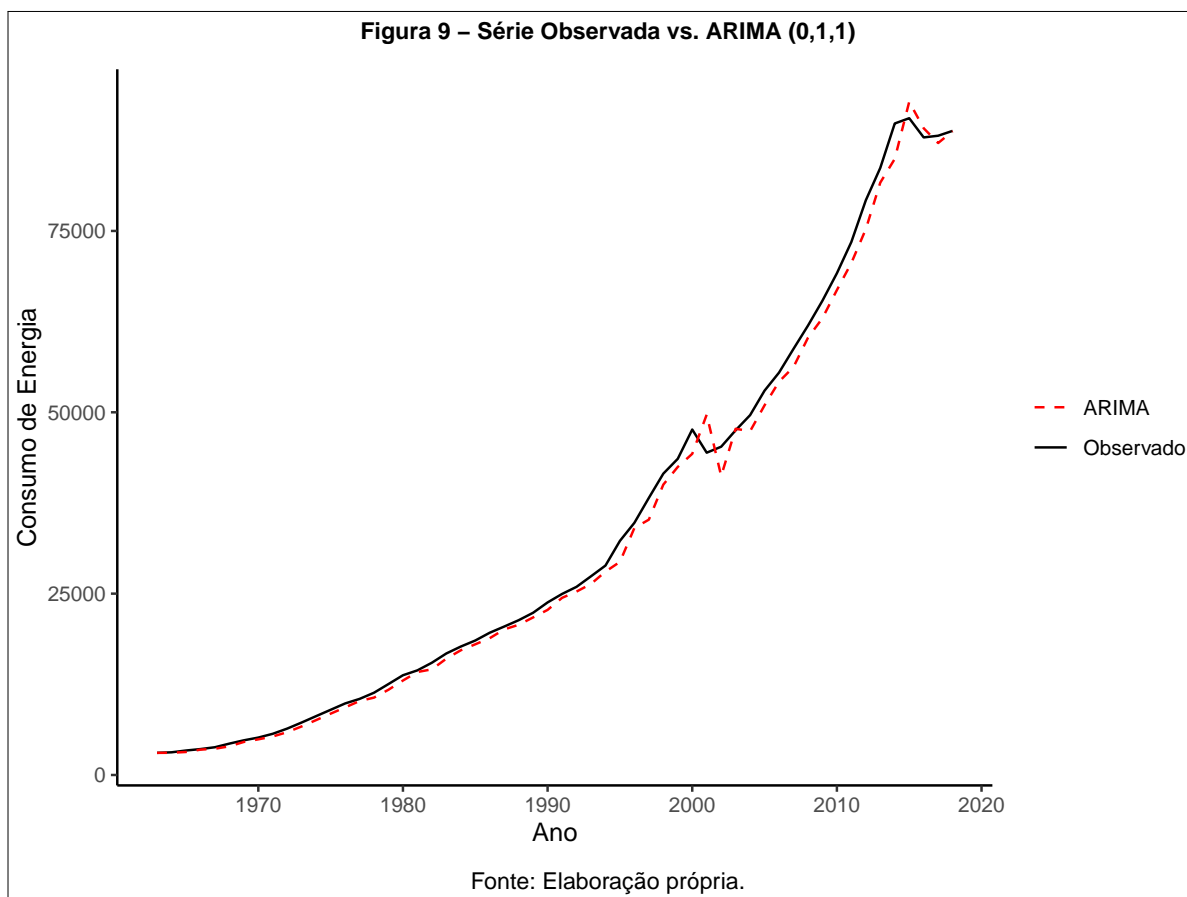
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

2.2.1.1 Resíduos:


Abaixo, a FIGURA 8 contendo o gráfico ACF e PACF dos resíduos. Visualmente, o gráfico ACF não indica correlação entre os resíduos, enquanto o gráfico PACF indica no lag 2.



A FIGURA 8 mostra a adequação do modelo a série. O gráfico indica que o modelo ARIMA(0,1,1) conseguiu se adequar a série proposta.



A condição de normalidade dos resíduos foi verificada por meio do histograma (FIGURA 10), do teste de *Shapiro-Wilk* e do teste *Anderson-Darling*.



Sob as hipóteses:

H_0 : Os resíduos são normais H_1 : Os resíduos não apresentam normalidade.

Shapiro-Wilk normality test

data: residuos

W = 0.8627, p-value = 1.353e-05

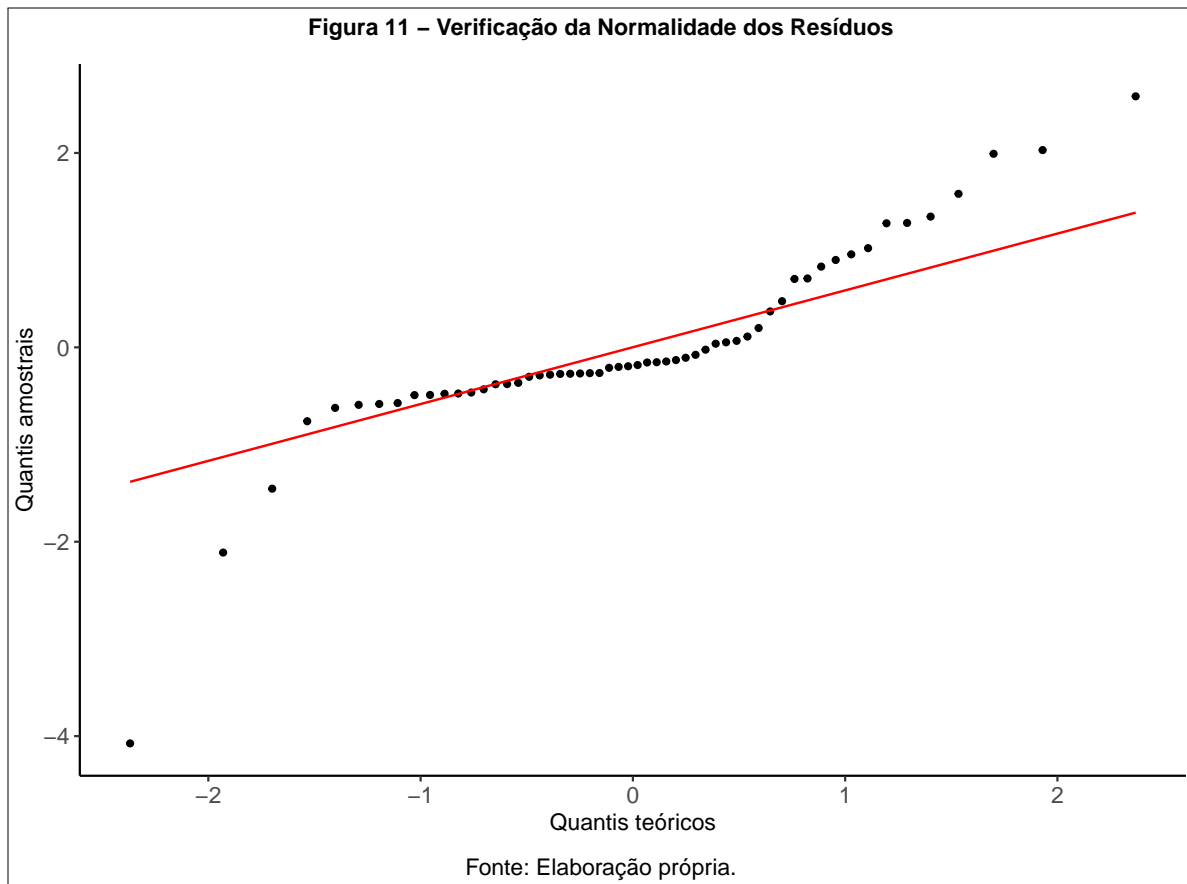
Anderson-Darling normality test

data: residuos

A = 2.7407, p-value = 5.409e-07

A hipótese nula foi rejeitada em ambos os testes, sendo possível inferir que os resíduos não apresentam normalidade.

Por meio do gráfico Q-QPlot (FIGURA 10) a seguir, confirmou-se a ausência de normalidade:



Abaixo na TABELA 1, as estatísticas do modelo e dos resíduos:

2.2.2 Modelo 2:

Proposta de novo modelo e utilizando a função `auto.arima`:

Series: y

ARIMA(1,2,1)

Coefficients:

	ar1	ma1
	0.4559	-0.9166
s.e.	0.1489	0.0697

Table 1: Tabela 1 - Métricas do modelo 1.

Estatística	Valor
MSE	1781.519
AIC	984.919
BIC	985.15
Média	949.778
Sd	1520.866
Skewness	-0.629
Kurtosis	7.35
p_valor_Shap	1.353e-05
Fonte:	Elaboração própria.

```
sigma^2 = 2148302: log likelihood = -469.76
AIC=945.52 AICc=946 BIC=951.49
```

Training set error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE	ACF1
Training set	200.7039	1412.392	779.164	1.171654	2.211825	0.4398532	-0.07117517


z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)
ar1	0.455878	0.148930	3.061	0.002206 **
ma1	-0.916634	0.069686	-13.154	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

A função `auto.arima` retornou um modelo ARIMA(1,2,1) com componente MA e AR significativos.


Abaixo, na FIGURA 12, o gráfico da série analisada e o modelo ajustado:



2.2.2.1 Resíduos Modelo 2:

2.2.2.1.1 Autocorrelação:

A FIGURA 12 abaixo mostra o gráfico de linha dos resíduos bem como os correlogramas.



A seguir, foi realizada a análise de independência de resíduos (*Box.test*), sob as hipóteses:

H_0 : Não há autocorrelação dos resíduos H_1 : Os resíduos estão correlacionados.

Box-Ljung test

```
data: residuals(modelo2)
X-squared = 27.489, df = 20, p-value = 0.1221
```

Os resíduos não estão autocorrelacionados, pois não existem evidências para rejeição da hipótese nula ($p\text{-value} = 0,12$) e graficamente também não apresentou nenhum indicativo de correlação.

2.2.2.1.2 Normalidade

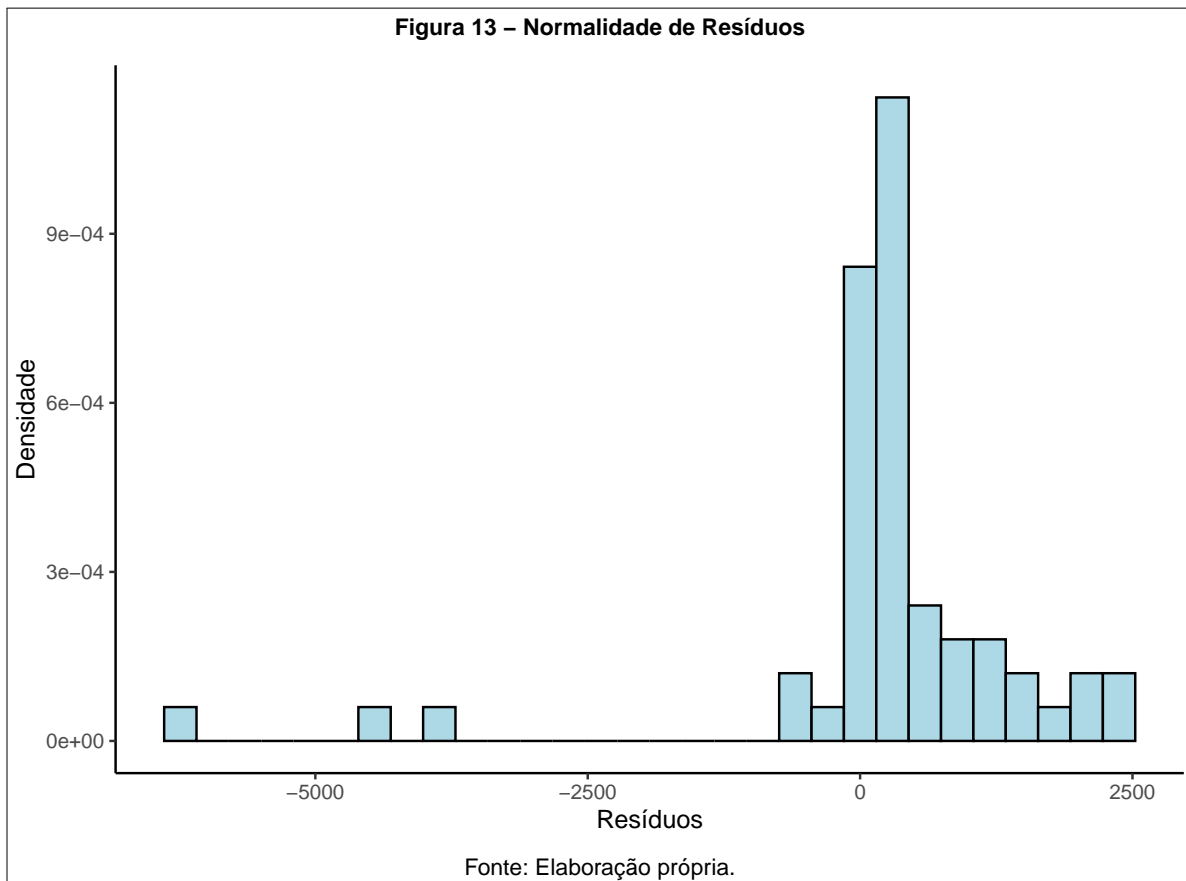
Para avaliar a normalidade dos resíduos e conferir se eles se configuram como ruídos brancos gaussianos, foi realizado o teste de *Shapiro.Wilk*, sob as hipóteses:

H_0 : Os resíduos são normais H_1 : Os resíduos não apresentam normalidade.

Shapiro-Wilk normality test

```
data: residuals(modelo2)
W = 0.68544, p-value = 1.139e-09
```

Com $p\text{-value } 1,13 \times 10^{-9}$, a hipótese nula é rejeitada, concluindo que os resíduos não são normais, porém como não possuem autocorrelação, podem ser considerados ruídos brancos não-gaussianos. A FIGURA 13 abaixo mostra o histograma dos resíduos, em que é possível conferir a ausência de normalidade graficamente.




A função *auto.arima* indicou um modelo com 1 componente regressora, 2 diferenciações e 1 componentede média móvel ARIMA(1,2,1)

2.2.3 Comparação entre os modelos criados pela função arima e autoarima.

Pelo critério AIC, o modelo 1 = 984,919, enquanto o modelo2 = 945,52. Logo, o modelo 2 explica melhor o fenômeno.

2.2.3.1 Visualização do modelo 2:

Na FIGURA 14 abaixo, estão os gráficos do modelo 2, sendo a FIGURA 14a o gráfico de linhas do modelo, enquanto as FIGURAS 14b e 14c representam os correlogramas. É possível identificar uma série sem “crescimento” e primeiro lag significativo.



Abaixo na TABELA 2 as estatísticas descritivas do modelo 2.

Table 2: Tabela 2 - Métricas do modelo e estatísticas dos resíduos.

Estatística	Modelo
MSE	1412.392
AIC	945.522
BIC	951.489
AICc	946.002
Media	200.704
Sd	1410.712
Skewness	-2.464
Kurtose	11.568
p_valor_Shap	1.139e-09
Fonte:	Elaboração
própria.	